

양식 1.

결과보고서

① 참가자 정보

지원부문	빅데이터 분석
개인·팀명	KKR과 아이스 초코
주 제(제목)	복합 장르 공연 콘텐츠의 수익성과 확장 가능성 분석; 공연시장 다양성과 지속 가능성을 위한 전략 제안

② 결과물 작성

• 개요

1) 분석/개발/연구 목적

공연예술 시장 내에서 장르 간 융복합 콘텐츠가 가지는 경제적 가치와 산업적 가능성을 실증적으로 분석하고, 공연 시장 내 다양성과 지속가능성 확보를 위한 정책적·실천적 전략을 제안하는 것을 목적으로 한다. 현재 공연시장은 대중음악을 중심으로 수익이 집중되는 반면, 연극, 국악, 클래식, 무용 등 비대중 장르들은 공연 건수는 많으나 실질적인 수익은 낮은 구조적 불균형을 겪고 있다. 이에 따라 콘텐츠 다양성이 위협받고 있으며, 공연산업 생태계의 지속 가능성 역시 저해받고 있다.

이러한 상황 속에서 새로운 대안으로 주목받고 있는 것이 바로 장르 간 융합을 시도하는 복합 공연 콘텐츠이다. 최근에는 국악과 디지털 아트, 클래식과 미디어 파사드, 연극과 무용의 결합, 인공지능과의 접목 등 다양한 형태의 융복합 공연이 시도되고 있다. 이러한 콘텐츠는 기존의 고정된 장르 구분을 넘어서는 창의적인 실험으로, 비대중 장르의 진입 장벽을 낮추고 신규 관객을 유입시키는 계기를 마련할 수 있을 것으로 기대된다.

하지만 현재 공연예술통합전산망(KOPIS)에서는 '복합' 장르를 단일 카테고리로 취급하고 있어, 구체적으로 어떤 장르 조합이 포함되어 있는지 확인하거나 성과를 유형별로 비교·분석하기 어렵다. 즉, 데이터상 '복합'은 존재하나, 그 내용은 비가시적이며 실질적 활용이 어려운 상태다. 이에 본 프로젝트는 이 같은 구조적 문제를 해결하고자 한다. 먼저 복합 장르 공연의 개념을 명확히 정의하고, 세부적인 장르 조합 유형을 체계적으로 분류한 뒤, 이를 기반으로 각 유형의 성과 및 공연 결과 특성 등을 정량적으로 분석하고자 한다. 나아가 이 데이터를 토대로 공연 제작자, 플랫폼, 정책 기관 등이 실제로 활용할 수 있는 실천적 전략을 제시할 것이다.

2) 배경 및 필요성

2024년KOPIS 공연시장 분석에 따르면 연극, 무용, 국악, 클래식 등 비대중 장르는 전체 공연의 77.5%를 차지하고 있음에도 불구하고, 티켓 판매액 비중은 45.9%에 불과하다. 반면, 대중음악은 전체 공연의 22.5%만을 차지하고도 매출 비중이 54.1%에 달해, 실질적인 수익이 특정 장르에 편중된 구조임을 보여준다. 이는 공연시장 내 콘텐츠의 다양성과 균형을 위협하는 요소로 작용하고 있으며, 장르 간 격차를 좁히기 위한 새로운 전략이 요구되는 상황이다.

이러한 가운데, 장르 간 융복합 콘텐츠는 기존 장르 구분의 경계를 넘는 창의적인 시도로 등장하고 있다. 다양한 형태의 복합 공연이 실제로 시장에 등장하고 있으며, 일부는 성공적인 관객 반응과 수익 실적도 기록하고 있다.




그림 1. 23년, 24년 최고 매출 복합 공연 5개

그러나 현재 KOPIS는 데이터에서는 이러한 공연들이 '복합'이라는 단일 항목으로 묶여 있어, 내부의 다양성과 성과 차이를 확인하기 어렵다. 이처럼 데이터 구조상 정보가 단일화되어 있다면, 복합 장르의 산업적 가치와 정책적 가능성을 객관적으로 평가하기 어렵고, 지원 전략을 설계하는 데에도 근거가 부족하다.

따라서 본 프로젝트는 공연시장의 지속 가능성과 다양성 확보라는 대전제 아래, 현재 '복합'이라는 범주로 뭉뚱그려진 장르들의 실제 조합과 성과를 분석 가능한 데이터로 구조화하고, 이를 바탕으로 공연 산업 전반의 전략 설계와 지원 시스템 개선에 기여하고자 한다.

3) 타 분석(분석부문), 서비스(개발부문)와의 차별성 및 독창성

공연시장 내 '복합' 장르의 실체를 드러내고, 그 경제적 가치를 데이터 기반으로 실증 분석한다는 점에서 기존 연구 및 통계 보고서와 뚜렷한 차별성을 지닌다.

첫째, 대부분의 공연 시장 분석은 장르별로 단순 구분된 수치 비교에 그치며, '복합' 장르는 단일 항목으로 분류되어 내부의 다양성과 구성이 전혀 드러나지 않는다. 이에 반해 본 프로젝트는 복합 콘텐츠 내부의 장르 간 조합을 세분화하고, 이를 새로운 분석 단위로 삼아 성과와 특징을 정밀하게 비교 분석한다. 이로써 데이터의 분류 체계 자체를 확장하고, 실질적인 활용 가치를 높이는 분석 구조를 구현한다.

둘째, 단일 장르 중심의 성과 비교에서 벗어나, 복합 콘텐츠가 어떤 방식으로 비대중 장르의 진입 장벽을 낮추고 관객 저변을 넓히는가에 주목한다. 이는 단순한 흥행 분석이 아니라 콘텐츠 전략과 소비자 접점 변화에 대한 분석으로, 공연시장의 구조적 문제를 해결할 수 있는 구체적 경로를 제시한다는 점에서 독창적이다.

셋째, 기존의 전통적인 성과 분석 방식인 Performance Indicator(PI) 분석에서 그치지 않고 새로

운, 다원화된 성과 지표 체계인 복합-저변 중심 Diffused Performance Indicator(D-PI)를 새롭게 설계하여 이를 통해 공연 기획·유통·플랫폼·정책 주체들이 실질적으로 활용 가능한 전략과 실행안을 제시한다

4) 주요 내용 및 특징

본 연구는 복합 장르 공연의 실체를 구체적으로 드러내고, 저변 확대 효과를 정량적으로 검증하기 위해 데이터 정제와 분석, 그리고 모형화를 체계적으로 수행하였다. KOPIS 원천 데이터는 공연별 구매와 판매 이력으로 구성되어 있었으나, 동일 공연이 회차 단위로 반복 기록되는 구조적 한계가 있었다. 이에 공연 단위 대표 레코드를 추출하고, 불일치 라벨과 고결측 컬럼을 제거하며, 이를 표준화 과정을 거쳐 신뢰 가능한 분석 신호를 확보하였다.

분석은 Google Colab 기반 파이썬 생태계에서 이루어졌으며, pandas, NumPy, scikit-learn, SciPy 등 검증된 도구를 활용하여 전처리, 지표 산출, 판정, 통계 검증, 원인 진단, 개선 처방까지 일관된 파이프라인을 구축하였다.

복합 장르의 성과를 정량화하기 위해 새로운 지표인 D-PI(Diffused Performance Indicator)를 설계하였다. 이는 관객 참여도(U), 규모와 접점(S), 가격 접근성(A)의 세 축을 중심으로 구성되며, 유료와 무료 공연의 구조적 차이를 반영하여 가중치를 달리 적용하였다. 또한 지역 편중 문제를 완화하기 위해 지역 격차 보정을 포함하였고, 접근성 점수를 가산하여 보다 많은 사람들에게 열린 공연을 우대하는 구조를 마련하였다. 이러한 지표는 단순한 수익성이나 점유율 중심의 평가를 넘어, 문화 다양성과 저변 확대라는 복합 장르의 본질적 가치를 포착할 수 있도록 설계되었다.

성과 비교 결과, 복합 공연의 평균 DPI는 51.98로 비복합 공연의 45.06보다 높게 나타났으며, 특히 가격 접근성(A)에서 우위를 보였다. 그러나 모든 복합 공연이 단일 평균을 능가하는 것은 아니었다. 유료 공연의 성공률은 37.7%로 낮았으나 성공 시 성과 폭이 컸고, 무료 공연은 성공률이 40.4%로 약간 높았으나 성과 분포가 불안정했다. 이는 복합 장르 공연이 본질적으로 고위험·고성과 구조를 지니고 있음을 의미한다.

실패 원인을 따로 분석한 결과, 유료 공연은 관객 참여율(U)의 저하가 핵심 병목으로 확인되었고, 무료 공연은 참여율과 규모(S)를 동시에 개선해야 하는 구조적 한계가 드러났다. 가격 접근성(A)은 무료 공연에서는 상수처럼 작동해 개선 여지가 거의 없었다. 이를 바탕으로 랜덤포레스트 회귀 모델을 적용하여 실패 표본이 성공선(단일 평균)을 넘기 위해 필요한 최소 개선량을 산출하였다. 그 결과 유료 공연은 참여율을 약 +0.10 개선하고 소폭의 규모와 가격을 보강하는 것만으로도 80%의 실패 사례를 성공으로 전환할 수 있었던 반면, 무료 공연은 참여율과 규모를 동시에 더 크게 개선해야 했음에도 불구하고 성공 전환률은 63%에 그쳤다. 이는 유료 공연이 저비용·고효율적 개선 전략으로 성과 전환이 가능한 반면, 무료 공연은 구조적 개선이 병행되어야 한다는 점을 시사한다.

이러한 분석을 통해 본 연구는 복합 공연 성과를 단순히 진단하는 데서 그치지 않고, 실패 원인을 규명하고 개선 방향을 정량적으로 제시하는 실행형 도구로 확장하였다. 나아가 정책 및 실무

차원에서는 공연 기획 단계에서 조합별 성공 가능성을 사전에 평가하고, 예산 대비 효과를 극대화하며, 최소 개선량을 KPI로 설정하는 데 활용할 수 있다. 궁극적으로 본 연구는 복합 장르 공연의 기획·편성, 정책 평가, 플랫폼·서비스화까지 연계 가능한 데이터 기반 의사결정 체계를 마련했으며, 문화 예술 생태계에서 복합 전략의 저변 확대 효과를 지속적으로 증명할 수 있는 기반을 제공한다.

• 세부 내용

1) 분석/개발/연구 방법

1) 활용 데이터(선정 근거와 정제 기준)

복합' 장르를 분석 가능한 구조로 재정의하기 위해, 우선 공연 단위의 신뢰 가능한 신호를 확보하는 데 초점을 두었다. 원천 데이터는 공연별 구매·판매 이력(회차 단위 기록 다수)로 구성되어 있었고, 이는 동일 공연에 대한 반복 기록이 존재하는 구조였다. 따라서 공연의 고유 특성을 보존하기 위해 공연당 하나의 대표 레코드로 축약하는 정제를 수행했다.

인물·조직명은 이름 표준화(괄호, '외(外)' 등 제거, 쉼표 분리 및 트림)를 수행했다. 이는 동명이인 처리의 전제 조건이었고, 그래프 노드의 중복·누락을 방지하려는 조치였다.

복합 장르의 실체를 드러내려면, 우선 라벨의 정합성과 결측 최소화가 필요했다. 불일치 라벨과 고결측 컬럼을 그대로 두면 이후 모델의 판단과 지표 산출에서 체계적 편향이 발생한다. 따라서 선별적 제외와 표준화가 우선이었다.

2) 활용 도구/환경(선택 이유와 적용 범위)

작업 환경은 Google Colab을 사용했고, Google Drive를 통해 데이터와 모델 산출물을 관리했다. Colab을 선택한 이유는 여러 번의 전처리·모델링·튜닝 반복이 필수였으며, 파일 버전 관리가 용이하고, 그래프 신경망 실험에 필요한 파이썬 기반 생태계를 안정적으로 운용할 수 있는 일관된 실험환경을 유지할 수 있었기 때문이었다. 분석 구조와 도구 매핑은 아래와 같이 사용하였다.

1. 데이터 적재·정규화(pandas/NumPy)
: 장르명 정규화(A+B 키), 좌석수→규모 구간화, 지표 스케일 검증(0-1 클리핑)
2. 판정(Mean 기준)과 전반 비교(pandas + Matplotlib)
: 복합 vs 비복합 평균 지표, 성공/실패 비율·분포(boxplot)
3. 통계 검증(SciPy)
: 성공 vs 실패 Welch t-test(양측) + (선택) 효과크기/신뢰구간
4. 원인 분해(실패 컷인, pandas + Matplotlib)
: U/S/A 분포 차이 및 상관 구조
5. 개선 처방(모형 기반, scikit-learn + pandas)
: RF 회귀 예측엔진으로 성공선 돌파 최소 $\Delta(U/S/A)$ 탐색(그리드)
6. 유료/무료 현실 제약 반영
: 결과 반출(pandas + Matplotlib)

7. CSV utf-8-sig 저장(한글 환경 완전 호환),
: 보고서용 도표·캡션 규격화

Python을 택한 이유는 재현 가능한 엔드투엔드 파이프라인을 검증된 생태계(pandas / NumPy / scikit-learn / SciPy / Matplotlib) 안에서 구축해, 정책·실무 현장에서 바로 쓰이는 방안(최소 $\Delta U/\Delta S/\Delta A$)까지 연결하기 위함이다.

또한, raw data를 원하는 컬럼을 추출하여 가공 및 재사용을 원활하게 하기 위해서 MySQL을 통해 SQL문을 사용하였고, 서버를 구축하여 모두가 원활하게 사용할 수 있도록 하였다.

3) 프로세스(히스토리 포함한 단계별 설계)

본 프로젝트의 전체 프로세스는 다음과 같은 연속 흐름으로 설계·수행했다.

1. 데이터 수집·적재를 마친 뒤, 공연 단위 대표 레코드로 축약 및 복합/비복합 구분에 체계적 오류를 유발할 항목을 제거하였다.
2. 결측치 EDA를 통해 고결측 컬럼으로 인한 학습 신호 분산을 줄여, 신뢰 가능한 피처에 집중하려는 선택 하고자 하였다.
3. 이름 표준화(불필요 문자 제거·분리·트림)를 수행했다. 이는 그래프 구축 과정에서 동명이인 충돌과 노드 중복을 최소화하려는 목적이었다.
4. 동명이인 처리 원칙을 중분류 기준으로 확정했다. 또한 GNN을 사용하고자 그래프 구축단계에서 공연·인물(출연/제작)·제작사·장르를 노드, 참여/소속을 엣지로 구성했다. 2-Layer GCN구조를 사용했고, 다중라벨예측으로 복합 공연의 상위 2개 장르(A+B)를 도출했다.
5. 성과지표 산출(D-PI)단계 지표 산출을 위한 핵심 구성 요소인 U(참여도), S(접점/규모), A(가격 접근성)은 모두 전역 정규화 및 백분위 기반 지표로 계산되며, 각각의 특성에 맞는 방식으로 정량화되었다. 유료/무료 공연에 따라 합성 규칙을 달리했고, 지역별 편중 현상을 고려하기 위해 지역 격차 보정을 적용하였다.
6. 이렇게 산출된 성과지표(DPI)를 분석하여 성과 비교 후 판정-원인-개선 3단계에 걸쳐 개선점을 제고하고자 하였다.

결과 및 성과 지표 추출에서 모든 자료를 사용한다면 코로나 팬데믹 같은 외생 변수로 인해 지표 비교의 타당성이 깨진다. 따라서 성과지표 산출 시에는 2023, 2024년도의 성과만 추출하여 사용하였다.

4) 분석 모형(설계 의도와 입력/출력 정의)

모형은 복합 장르의 실체를 예측 가능하게 만들기 위한 다중라벨 분류 구조로 설계했다. 입력은 그래프였고, 출력은 장르 레이블 공간의 확률 벡터였다.

그래프 입력 정의: 노드 = 공연 / 인물(출연·제작) / 제작사 / 장르. 엣지 = 공연—인물(참여), 공연—제작사(소속), 공연—장르(라벨 참조).

엣지 가중치 입력: TF-IDF 계열 가중으로 엣지별 연결 강도를 부여했다. 이는 동일 인물의 다작 효과를 줄이고, 특정 조합에서 나타나는 강한 연관성을 더 선명하게 반영하려는 의도였다.

출력 정의: 각 공연 노드에 대해 장르별 로짓/확률을 산출했고, 복합 공연은 상위 2개 확률의 조합(A+B)으로 결정했다.

복합의 본질은 다중 커뮤니티에 동시에 속한 위치였고, 이는 그래프 임베딩 공간에서 두 장르 노드와의 근접으로 자연스럽게 표현되었다. 따라서 다중라벨 출력이 문제 정의에 부합했다.

5) 알고리즘(GNN 구성과 학습 규칙)

알고리즘은 GCN 기반 2-계층 구조로 구성했다. 첫 레이어는 64차원 은닉 채널로 임베딩을 변환했고, 두 번째 레이어는 장르 수만큼의 다중라벨 출력을 생성했다. 손실 함수는 BCEWithLogitsLoss를 사용했고, 클래스 불균형을 고려해 pos_weight를 적용했다. 최적화는 Adam(lr=0.01)으로 약 100 epoch 학습했다. 학습 데이터는 앞서 정제한 그래프를 기반으로 하되, 복합 공연의 Top-2 예측을 최종 산출 규칙으로 사용했다. 노드 수는 대규모(142,215개)였고, 이는 공연·인물·제작사·장르를 망라하는 범위였다.

복합 장르 예측의 핵심은 노드 간 메시지 패싱을 통해 관계 맥락을 학습하는 것이다. GCN 2-계층은 과도한 복잡도 없이 협업 패턴을 학습하기에 적절했다고 판단했다. pos_weight는 소수 장르 학습 신호의 희석을 방지하려는 보정이었다.

6) 새로운 성과지표

복합 장르는 여러 표현 방법들과 예술 형식이 혼합되어 구성 되어 있으며 특정 문화나 장르에 국한되지 않는 다양성과 포용성을 가지고 있다. 복합 장르의 경우 단기적인 수익보다 문화 다양성의 확산 및 접근성 확대 등 공공 가치 실현이 중요한 목표가 될 수 있기에 기존의 전통적인 성과 분석 방식인 Performance Indicator(PI)로는 판단하기가 어렵다고 생각하였다. 따라서 본 프로젝트에서는 수익성 중심의 평가를 벗어나 다원화된 성과 지표 체계인 복합-저변 중심 Diffused Performance Indicator(D-PI)를 새롭게 설계하고자 하였다.

7) 성과 분석

앞선 분류와 성과지표 점수화를 바탕으로, 복합 장르 공연이 단일 장르 공연보다 관객 저변 확대 효과를 가지는지를 검증하기 위하여, 단계적 비교와 검증 과정을 거쳤다. 연구의 방법론은 크게 세 가지 축으로 구성되며, 각각의 세부 내용은 다음과 같다.

a. 복합 vs 비복합 비교

우선 복합 공연과 단일 장르 공연의 성과를 비교하였다. 비교 지표로는 종합 확산 지수(DPI_plus)와 함께, 참여 안정성(U_participation), 규모 확장성(S_scale), 가격 접근성(A_afford)을 설정하였다. 이는 단순히 DPI 수치의 고저를 판별하는 수준을 넘어서, 복합 공연이 구조적으로 강점을 가지는 영역과 약점을 드러내는 영역을 다각도로 확인하기 위함이었다.

복합 공연은 장르 융합의 특성상 관객 저변 확대 가능성을 내재하지만, 동시에 가격 상승이나 장르 간 충돌로 인한 부정적 효과를 수반할 수 있다. 따라서 전반적인 성과 차이를 먼저 검토하는 과정은 필수적이었다. 이 비교를 통해 복합 공연이 참여 확대·접근성 강화 측면에서 우위를 가지는지, 혹은 비복합 공연이 안정성과 상업성 측면에서 상대적으로 유리한지를 구체적으로 규명할 수 있었다

b. 공연장 규모 분류

다음으로 공연장 규모에 따른 차이를 분석하였다. 공연장은 좌석 수를 기준으로 소규모(300석 이하), 중규모(301~1000석), 대규모(1001석 이상)로 구분하였다. 이러한 구분은 공연장 규모가 관객 경험과 접근성에 직접적인 영향을 미친다는 점에 근거하였다. 대규모 공연장은 네트워크 효과가 크게 발휘될 수 있어 복합 장르 공연의 확산 효과를 극대화할 가능성이 컸다. 소규모 공연장은 밀도 있는 관객 경험과 실험적 성격이 강화되어 장르 융합이 창의적으로 작동할 수 있다. 중규모 공연장은 두 특성의 중간 지점에 위치하여 안정성과 확산성을 동시에 확보할 수 있었다.

c. 장르 조합 비교 (A+B vs A, B)

복합 장르의 성과를 단일 장르 대비로 검증할 때, A+B의 DPI가 (A+B)/2 평균 이상일 경우를 성공으로 정의하였다(Mean 기준). 이 기준은 시너지 효과 검증에 합리적이며, 관객 기대치와도 부합한다. 성과 비교는 단순한 수치 비교에 그치지 않고 산점도(scatterplot), 박스플롯(boxplot), 히트맵(heatmap) 등 다각적 시각화와 검증을 통해 복합 장르가 단순히 평균을 상회하는지 여부뿐 아니라, 어떤 장르 조합이 시너지를 내는지, 실패 조합의 주요 원인이 무엇인지를 보다 정밀하게 규명할 수 있었다. 이를 통해 결과 해석의 신뢰성을 높이는 동시에, 실무적으로는 공연 기획 시 유망한 조합을 선별하고, 실패 가능성이 높은 조합을 개선하는 전략을 마련하는 데 활용하고자 하였다.

7) 요약(설계 논리의 연쇄성)

본 프로젝트는 복합 장르의 가시화를 목표로, (a) 정합성 높은 데이터를 만들고, (b) 관계 구조를 학습하는 GNN으로 복합 A+B를 예측했으며, (c) 저변 확대의 핵심 축(U·S·A)을 분리·정규화·보정하여 정책 친화적 지표(D-Pi)를 산출하도록 설계했다. (d) 이를 통해 나온 파악 및 원인 분석을 통해 개선점을 제하고자 하였다.

2) 결과물

<① 복합 / 비복합 분류>

KOPIS에서 제공한 raw data는 공연별 구매·취소 이력이 행 단위로 누적되는 구조였다. 동일 공연이 회차·거래 단위로 반복 기록되어 공연 특성 비교에는 부적합했으므로, 공연 단위의 해석 가능성을 확보하기 위해 공연당 하나의 대표 레코드로 집약했다. 장르 체계는 KOPIS의 '장르명/세부장르명'이 각각 중분류/세분류에 해당했다. 복합과 비복합으로 분류를 하고자 하였을 때 아래와 같은 상황이 발생하였다.

서커스/마술을 비복합 장르에 넣으면 추후 복합 장르의 특정 중분류/세분류로 들어가게 되어 분

류에 오류가 생길 수 있고, 복합 장르에 넣기엔, 중분류 자체가 이미 서커스/마술로 되어 있어, 임의로 데이터를 바꿔서 쓰기에는 문제점이 있어 제외하였다.

다원/융복합 또한 복합 장르 분류에서 '공연 이외 시각예술 및 기술 등의 혼합 공연'이라는 설명으로 복합으로 분류 되어 있지만, 현재 특정 장르의 합으로 분류하기에는 적합하지 않다고 판단하여 제외하였다

위 내용을 바탕으로 분류를 한 결과 데이터는 비복합 장르의 공연은 총 72,611건, 복합 장르의 공연은 총 1,099건이었고, 각각 except_complex.csv, complex.csv로 가공하여 사용하였다.

<②복합 장르를 구별하기 위한 컬럼 선택>

장르를 구별하기 위해 사용할 컬럼을 전체 컬럼에서 뽑아 총 8개를 다음과 같이 선정하였다.

공연명 / 장르명 / 세부장르명 / 출연진내용 / 제작진내용 / 기획제작사명 / 원작자명 / 극작가명
--

각 컬럼의 특성을 파악하기 위해 연도별로 컬럼을 추출하여 결측치를 파악하였다.

연도	2020		2021		2022		2023		2024	
공연수	5399건		11872건		16787건		18780건		19774건	
컬럼명	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)
id	0	0	0	0	0	0	0	0	0	0
공연명	0	0	0	0	0	0	0	0	0	0
장르명	0	0	0	0	0	0	0	0	0	0
세부장르명	0	0	0	0	0	0	0	0	0	0
출연진내용	1182	21.89	2555	21.52	5057	30.12	5208	27.73	4455	22.53
제작진내용	3730	69.09	8253	69.52	12354	73.59	14233	75.79	13786	69.72
기획제작사명	244	4.52	682	5.74	1340	7.98	1327	7.07	589	2.98
원작자명	4600	85.2	10559	88.94	15277	91.0	17190	91.53	17725	89.64
극작가명	5221	96.7	11561	97.0	16323	97.24	18602	99.05	19667	99.46

표 1. except_complex 컬럼별 결측치

연도	2020		2021		2022		2023		2024	
공연수	85건		133건		213건		325건		360건	
컬럼명	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)	결 측 치 수	결 측 치 비율(%)
id	0	0	0	0	0	0	0	0	0	0
공연명	0	0	0	0	0	0	0	0	0	0
장르명	0	0	0	0	0	0	0	0	0	0
세부장르명	0	0	0	0	0	0	0	0	0	0
출연진내용	31	36.47	37	27.82	65	30.52	77	23.69	79	21.94
제작진내용	69	81.18	94	70.68	153	71.83	261	80.31	266	73.89
기획제작사명	8	9.41	10	7.05	24	11.27	19	5.85	12	3.33
원작자명	85	100	133	100	210	98.59	321	98.77	355	98.61
극작가명	85	100	133	100	213	100	325	100	360	100

표 2. complex 컬럼별 결측치

EDA 결과, 복합 및 비복합 장르 모두에서 원작자명과 극작가명의 결측률이 85.2%~99.46%로 매우 높아 신호-잡음비가 낮은 변수로 판단했고 장르 분류 변수군에서 제외했다

<③ 동명이인 처리>

비복합 장르 참여 이력을 출연진과 제작진 단위로 집계하는 과정에서 발생하는 동명이인 문제가 있었다. 이에 분류-중분류-세부장르의 세 가지 계층으로 매핑하여 분포를 검토하는 방식으로 수행됐다. 이름 문자열을 키로 하여 장르별 빈도를 비교했을 때 3가지 선택지가 존재했다.

대분류는 카테고리 수가 소수에 불과해(예: 뮤지컬, 연극, 음악, 무용 등) 이름 충돌을 충분히 분리하지 못했다. 예컨대 동일한 이름이 뮤지컬과 성악에 모두 등장하는 경우, 대분류만으로는 서로 다른 인물인지 동일 인물의 교차 활동인지 판별력이 부족하다.

반대로 세부장르는 성악과 기악처럼 지나치게 세밀하여, 실제로 장르 간 이동이 있는 한 사람을 다른 사람으로 오인할 위험이 커졌다. 결과적으로 세부장르 기준은 데이터의 자연스러운 장르 폭을 과소 추정하게 만들고, 극단적 희소성을 유발해 모델 학습과 해석을 어렵게 했다.

중분류는 두 극단 사이에서 균형 잡힌 분해 수준을 제공했다. 뮤지컬과 연극처럼 현업에서 구분의 실익이 큰 축은 분리하면서도, 국악과 무용처럼 활동 폭이 넓거나 교차 빈도가 있는 영역은 한 이름 안에서 합리적으로 묶인다. 실증 점검에서도 동일 이름의 장르 쏠림이 중분류 기준에서는 완화되었고, 소수 활동 장르의 존재를 소거하지 않으면서도 과도한 파편화가 발생하지 않았다.

예를 들어 박소영이라는 이름의 이력이 뮤지컬 38회, 연극 30회, 한국음악 1회, 무용 1회로 관측되는 경우, 중분류 기준을 적용하면 뮤지컬·연극 중심 활동가와 국악·무용 활동가를 현실적으로 구분할 수 있었고, 대분류에서의 과도한 응집이나 세부장르에서의 과도한 분산이 모두 완화되었다.

이상의 점검을 바탕으로 동명이인 처리는 중분류 단위에서 수행하기로 결정했다. 이 결정은 첫째, 이름 충돌로 발생하는 장르 쓸림과 왜곡을 완화하고, 둘째, 분석 결과의 해석 가능성과 실무 적용성을 동시에 확보한다는 근거에 기반한다. 실제 운영에서는 이름-중분류-역할(출연/제작)을 결합한 준식별자를 기본 키로 사용하고, 동일 키 내에서 활동 빈도를 집계한다. 필요한 경우에는 추가 보조 특징(소속단체, 주요 협업자, 활동 연도대 등)을 이용해 경계 사례만 수동 검증하는 방식으로 품질을 관리한다.

결론적으로, 동명이인 처리의 표준 단위를 중분류로 고정함으로써 장르 분류 테이블의 일관성과 신뢰도를 높이고, 이후 단계의 복합 판정, GNN, DPI 산출, 개선 시뮬레이션까지 동일한 기준으로 연결할 수 있는 데이터 거버넌스를 구축했다. 이는 모델 성능의 안정성과 결과 해석의 투명성을 동시에 향상시키는 선택이며, 향후 외부 식별자(예: 고유 인물 ID)가 확보되는 경우에도 중분류 기준 집계는 요약 계층으로 그대로 유지되어 비교 가능성을 보장한다.

<④ GNN 기반 복합 장르 세분화>

공연 설명 텍스트만으로는 복합 장르의 세부 구성이 모호해지기 쉬우므로, 우리는 이 네트워크를 이종 그래프(heterogeneous graph)로 정식화하고 GNN으로 학습하여 복합 공연의 세부 장르 조합을 추정했다. 핵심 아이디어는 공연 자체의 이름이 정보를 담기보다는, 그 공연이 어떤 사람·기관과 연결되어 있는가가 장르를 설명한다는 점이다. 따라서 공연 노드는 라벨의 대상이자 연결의 허브로 사용하고, 장르는 연결 패턴으로부터 간접적으로 추정한다.

4.1 그래프 설계와 데이터 구조

그래프는 공연, 인물(출연·제작), 그리고 제작사/기획사 세 종류의 노드로 구성했다. 공연 노드는 출연진·제작진·제작사 노드와 양방향 엣지로 연결된다. 이렇게 정의하면 공연-사람-기관이 뒤얽힌 실제 제작 생태계를 비교적 손실 없이 반영할 수 있고, 이종 관계를 다루는 GNN(예: Hetero-GNN, GraphSAGE, HAN 등)을 적용하기 용이하다. 공연명은 고유 ID로만 쓰이며, 학습되는 정보는 이름 문자열이 아니라 연결 구조다. 이는 “제목만 보고 장르를 맞히기보다는, 감독·배우·제작사 조합을 보면 장르가 보인다”는 영화 도메인의 직관과 동일하다.

4.2 학습 데이터 구축 및 학습(노드 사전 구축)

단일 장르 공연을 모아놓고, 이전에 동명이인 처리가 진행된 `except_complex.csv`를 사용했다. 이 데이터는 각 공연에 확정된 단일 장르 라벨이 있어 감독 학습(supervised learning)에 적합하다. 한편 실제로 장르 조합을 알고 싶은 복합 공연은 라벨이 없으므로, 학습된 모델로 추론하였다. 두 데이터프레임(단일·복합)을 결합해 하나의 통합 그래프를 만든 뒤, 단일 공연 노드만 라벨을 가지고 학습 단계에 참여시키고, 복합 공연 노드는 같은 그래프 위에서 임베딩을 얻은 뒤 예측을 진행하였다.

그래프의 노드는 공연(허브), 인물(출연/제작), 제작사/기획사, 장르(단일 라벨 학습용)로 구성된다. 중복 컬럼 정리와 함께 `source(df/df_complex)-original_index`를 부여해 공연 노드의 추적 가능성을 높였다

```

# (Cell 7) 노드 먹서너리
import re

node_dict, current_id = {}, 0

# 중복 컬럼 제거 및 식별자 부여
df = df.loc[:, ~df.columns.duplicated()].reset_index(drop=True)
df['original_index'] = df.index; df['source'] = 'df'
df_complex = df_complex.loc[:, ~df_complex.columns.duplicated()].reset_index(drop=True)
df_complex['original_index'] = df_complex.index; df_complex['source'] = 'df_complex'

all_performances = pd.concat([df, df_complex], ignore_index=True)

# 인물/제작진/제작사 노드
for _, row in all_performances.iterrows():
    for name in row['출연진내용_standardized'] + row['제작진내용_standardized']:
        key = f"인물_{name}"
        if key not in node_dict:
            node_dict[key] = current_id; current_id += 1

    for name in row['제작사_standardized']:
        key = f"제작사_{name}"
        if key not in node_dict:
            node_dict[key] = current_id; current_id += 1

# 공연 노드
for _, row in all_performances.iterrows():
    key = f"공연_{row['source']}_{row['original_index']}"
    if key not in node_dict:
        node_dict[key] = current_id; current_id += 1

# 장르 노드(학습 신호용)
genre_names = sorted(list(
    df['장르명'].apply(lambda x: re.sub(r'\s*(.*?)', '', str(x)).strip()).unique()
))
for g in genre_names:
    key = f"장르_{g}"
    if key not in node_dict:
        node_dict[key] = current_id; current_id += 1

num_nodes = len(node_dict)
print(f"[INFO] 총 노드 수: {num_nodes}")

```

그림 2. GNN 그래프 노드 설정 코드

엣지는 공연 ↔ 인물/제작진/제작사의 참여 관계로 정의했다. 단, 동일 참여자 이름이라도 작품 간 중요도가 다를 수 있어, 작품별 텍스트 코퍼스를 만들고 그 안에서의 토큰 가중치를 TF-IDF로 계산해 엣지 가중치로 사용했다. 이로써 “주요 스태프/제작사”의 영향력이 그래프 합성곱에 더 강하게 반영된다.

```

# (Cell 8) 엣지와 가중치
import numpy as np, torch
from sklearn.feature_extraction.text import TfidfVectorizer
from torch_geometric.utils import to_undirected, add_self_loops
from tqdm import tqdm

edges, edge_weights = [], []

# 공연별 코퍼스 → TF-IDF
corpus = [
    " ".join(row['출연진내용_standardized'] + row['제작진내용_standardized'] + row['제작사_standardized'])
    for _, row in all_performances.iterrows()
]
vectorizer = TfidfVectorizer(token_pattern=r"[^ ]+")
tfidf = vectorizer.fit_transform(corpus)

# 참여 엣지 구축 + TF-IDF 가중치 주입
for perf_idx, row in tqdm(all_performances.iterrows(), total=len(all_performances), desc="Edges Build"):
    perf_key = f"공연_{row['source']}_{row['original_index']}"
    perf_id = node_dict[perf_key]

    participants = row['출연진내용_standardized'] + row['제작진내용_standardized'] + row['제작사_standardized']
    for name in participants:
        pkey = f"제작사_{name}" if name in row['제작사_standardized'] else f"인물_{name}"
        if pkey in node_dict:
            pid = node_dict[pkey]
            edges.append([perf_id, pid])

            col_idx = vectorizer.vocabulary_.get(name, None)
            w = float(tfidf[perf_idx, col_idx]) if col_idx is not None else 0.0
            edge_weights.append(w)

# Torch 텐서 변환 + 무방향화 + self-loop
edges_array = np.array(edges, dtype=np.int64)
edge_index = torch.tensor(edges_array.T, dtype=torch.long)
edge_weight = torch.tensor(edge_weights, dtype=torch.float)

edge_index, edge_weight = to_undirected(edge_index, edge_weight, num_nodes=num_nodes)
edge_index, edge_weight = add_self_loops(edge_index, edge_weight, fill_value=1.0, num_nodes=num_nodes)

edge_index, edge_weight = edge_index.to(device), edge_weight.to(device)

```

그림 3. GNN 그래프 엣지 설정 코드

모델은 ID 임베딩 → GCNConv → Dropout → GCNConv의 단순·해석 가능한 구조를 사용했다. 출력은 각 장르 차원의 로짓이며, 클래스 불균형을 완화하기 위해 'BCEWithLogitsLoss'를 적용했다. 검증에서는 로짓에 시그모이드를 취해 확률로 변환한 뒤, 임계값으로 이진화하여 Micro/Macro-F1, Hamming Accuracy를 확인했다. 임계값은 이후 복합 태깅 규칙에서도 동일 좌표계로 사용한다.

```

# (Cell 12) 평가
from sklearn.metrics import f1_score, hamming_loss

def evaluate_multilabel(y_true, probs, threshold=0.3):
    y_pred_bin = (probs > threshold).astype(int)
    micro_f1 = f1_score(y_true, y_pred_bin, average="micro", zero_division=0)
    macro_f1 = f1_score(y_true, y_pred_bin, average="macro", zero_division=0)
    hamming = 1 - hamming_loss(y_true, y_pred_bin)
    return micro_f1, macro_f1, hamming

model.eval()
with torch.no_grad():
    logits = model(edge_index, edge_weight)
    probs = torch.sigmoid(logits)

val_idx = torch.where(data.train_mask)[0]
y_true = y[val_idx].cpu().numpy()
micro_f1, macro_f1, hamming = evaluate_multilabel(y_true, (probs[val_idx] > 0.5).int().cpu().numpy(), threshold=0.3)
print(f"Micro-F1: {micro_f1:.4f}, Macro-F1: {macro_f1:.4f}, Hamming Accuracy: {hamming:.4f}")

```

그림 4. GNN 임계값 및 검증 코드

4.3 복합 공연 추론과 태깅 규칙

학습이 완료되면 복합 공연 노드에 대해 임베딩을 계산하고, 장르 확률 분포를 예측한다. 분포에서 상위 두 개의 장르를 조합해 복합 태그를 부여하거나, 사전에 설정한 임계값을 넘는 모든 장르를 조합해 다중 태그를 부여한다. 예를 들어 어떤 공연의 예측 확률이 {연극 0.55, 국악 0.35, 무용 0.10}이라면 “연극+국악”으로 태깅된다. 이렇게 얻어진 조합은 KOPIS의 포괄적 “복합” 라벨을 구체적인 장르 쌍으로 분해해 주며, 이후 DPI 분석과 처방 단계에서 장르 조합별 성과 차이를 정밀하게 다룰 수 있게 한다 아래는 복합 공연 노드를 예측한 결과이다.

공연명	예측복합장르	장르1	확률1	장르2	확률2
비오케이 문화산책 (10월)	한국음악+서양음악	한국음악	0.770280838	서양음악	0.494528
손병호 & 최지연과 함께하는 여민락 콘서트, 지금 뛰다: NOW JUMP [세종] (8월)	연극+한국음악	연극	0.994673073	한국음악	0.021049
제 24회 전국 제음악제 DCMF, 콘쿠오레 : 챔베르크의 밤 150 [대전]	서양음악+한국음악	서양음악	0.870058298	한국음악	0.133769
3팀 3색 가을 콘서트 [울진]	무용+뮤지컬	무용	0.737532079	뮤지컬	0.38687
베스트슬립 수면콘서트	서양음악+대중음악	서양음악	0.767991304	대중음악	0.008246

표 3. 복합 공연 노드 예측 결과 (5가지 랜덤 추출)

4.4 구현 세부와 운영 고려사항 및 기대효과

타입별 그래프를 유지하기 위해 메타그래프 사양(노드 타입, 엣지 타입)을 명시하고, 배치 학습 시에는 타입별 메시지 전달 규칙을 구성했다. 노드 값은 0~1 범위로 클리핑하여 극단값이 임베딩 훈련에 과도한 영향을 주지 않도록 했고, 학습과 추론의 재현성을 위해 전처리 사전을 고정하고, 모델 체크포인트와 라벨 인코더를 함께 진행하여 버전 관리를 용이하게 하였다.

이 접근은 텍스트 의존을 줄이고 참여 네트워크 자체를 특징으로 사용함으로써, 인력·기관의 장르적 편향이 새로운 작품에도 자연스럽게 투영되는 장점을 갖는다. 동일 인물이 국악·연극 쪽에서 꾸준히 활동했다면, 새롭게 등장한 복합 공연에서도 그 신호가 반영되어 “연극+국악” 같은 조합이 안정적으로 예측된다. 또한 복합을 장르쌍·장르셋으로 바꿔, 이후 DPI 모델과 처방 알고리즘을 장르 조합 수준에서 연결할 수 있고, 캠페인·공간 정책을 조합별로 차등 설계하는 운영적 의사결정이 가능해진다

<⑤ 복합 장르 공연 성과 분석(D-PI)>

복합 장르는 단일 장르 공연과 달리 다양한 예술 형식과 표현 방식이 혼합되어 구성되며, 관객에게 보다 풍부한 문화적 경험을 제공할 수 있는 장르적 특성을 갖고 있다. 이로 인해 복합 장르는 단순한 관람을 넘어, 다양한 문화적 정체성과 예술적 실험을 접할 수 있는 통로로 기능하며, 관객층의 문화적 저변을 넓히는 데 기여하는 장르로서의 가치가 크다. 특히, 장르 간의 경계를 넘나

들며 새로운 감각과 접근을 제공하는 복합 장르는 문화 향유의 기회를 확장하고, 특정 문화나 장르에 국한되지 않는 다양성과 포용성의 상징적인 플랫폼으로 기능할 수 있다는 점에서 공연 예술 생태계 내 전략적으로 중요한 위치를 차지한다.

그러나, 수익성, 매출, 티켓 판매량 등 정량적이고 상업적인 지표는 이러한 복합 장르의 문화적 의의와 사회적 파급력을 온전히 포착하기 어려운 한계가 존재한다. 복합 장르의 경우, 단기적인 수익보다 문화 다양성의 확산과 접근성 확대 등의 공공적 가치 실현이 중요한 목표가 될 수 있기 때문에, 기존의 전통적인 Performance Indicator(PI)로는 복합 장르의 성과를 적절히 판단하기 어렵다.

따라서 본 프로젝트에서는 수익성 중심의 평가를 벗어나, 다양한 문화 장르와 관객을 포용할 수 있는 다원화된 성과지표 체계인 **복합-저변 중심 Diffused Performance Indicator(D-PI)**를 새롭게 설계하고자 하였다.

1) 데이터 전처리 및 파생 컬럼 생성

D-PI 지표 산출을 위해 아래와 같이 파생 컬럼을 정의하고, 주요 산식을 구성하였다. 각 컬럼은 원시 데이터에서 가공된 값이며, 지표 해석의 기초가 된다. 또한, 파생 컬럼 생성 전후로 데이터 전처리 및 보정을 진행하였다.

본 분석에서는 파생 컬럼 생성을 위한 기초 데이터를 정제하기 위해, 다음과 같은 1차 전처리 과정을 수행하였다.

1. 좌석수 0건 제거

공연 좌석수가 0으로 입력된 사례는 실질적인 공연이 이루어졌다고 보기 어려운 경우가 많아, 해당 데이터를 분석 대상에서 제외하였다. 이를 통해 초기 데이터의 신뢰성을 확보하였다.

2. 판매좌석수 보정 로직 적용

동일 공연명과 동일 공연일시는 하나의 공연 회차로 간주하고, '회차별_판매좌석수'를 다음 기준에 따라 보정하였다.

- 보정 대상 조건:

(1) 판매좌석수가 1인 경우

(2) 좌석수가 0이 아닌데 판매좌석수가 좌석수를 초과하는 경우

- 보정 방법:

예매(구분값 = 1)의 좌석수 합 - 취소(구분값 = 2)의 좌석수 합

→ 해당 값을 회차별_판매좌석수로 사용

파생 컬럼	정의	사용하는 컬럼
총_공연회차	한 공연이 가진 고유 회차 수	공연명, 공연일시
평균_판매좌석수	판매좌석수의 평균	회차별_판매좌석수, 총_공연회차

예매금액_합계	예매금액 총합 - 취소금액 총합	예매/취소구분, 예매/취소금액
판매좌석수_합계	전체 판매좌석수의 합	회차별_판매좌석수
최종_좌석점유율	판매좌석수 합 ÷ 좌석수 합	회차별_판매좌석수, 좌석수
평균판매단가	예매금액 합 ÷ 판매좌석수 합	예매금액_합계, 판매좌석수_합계
회차당매출	예매금액 합 ÷ 총 공연회차	예매금액_합계, 총_공연회차
접근성	공연 시설·교통 편의 등 값 합산	편의시설, 장애인 시설, 주차시설

표 4. 파생컬럼 생성

2) 자체적 성과 지표 개발

2.1. 복합 저변-중심 D-PI 정의

D-PI는 성과지표의 구조적 측면에서도 기존 PI와 뚜렷한 차별점을 가진다. 아래는 3가지 차별점에 대해 서술한 내용이다.

첫째, 단순 매출이나 점유율 중심의 성과 평가에서 벗어나, 관객 참여도(U), 문화 접점 및 규모(S), 가격 접근성을 고려한 수익성(A)이라는 세 가지 핵심 축을 기반으로 지표를 설계하였으며, 각 요소는 목적에 따라 유동적인 가중치를 부여받는다. 특히 유료 공연과 무료 공연은 각각 다른 경제적 기반과 문화 정책 목표를 지니기 때문에, 유/무료 공연을 구분하여 별도 가중치를 적용하고, 구조적 형평성을 고려한 평가 체계를 구성하였다.

둘째, 지역 간 불균형 문제를 완화하기 위해, 지표 산출 과정에 지역 보정 알고리즘을 포함하였다. 이는 지역별 표본 크기와 평균 성과 차이를 반영하여, 특정 지역에 편중되지 않는 정량적 균형성을 추구한다. 복합 장르 공연이 수도권에 집중되기 쉬운 현실을 감안할 때, 지역 격차 보정은 문화 정책적 의미에서도 중요한 기능을 수행한다. 이를 통해 D-PI는 지역 문화 불균형을 정량적으로 식별하고, 공연 유통 및 지원정책의 전략적 분산을 유도할 수 있다.

셋째, D-PI는 접근성 점수를 기반으로 한 소프트 보너스 가중치 시스템을 통해, 공연장의 물리적 위치나 관람의 편의성 등 비가격적 접근성 요소를 실질적으로 반영하려 하였다. 이를 통해 단지 '값이 싸거나 많이 팔린 공연'이 아니라, 보다 많은 사람에게 열린 공연이 우대받을 수 있도록 설계하였다.

구분	정의	구성요소	지표 해석
U(참여도)	좌석 점유율 기반의 실질적 관객 참여도	최종_좌석점유율	높을수록 객석 활용도가 높음
S(접점/규모)	공연이 관객과 접촉한 물리적 범위	총_공연회차, 판매좌석수_합계, 평균_판매좌석수	높을수록 공연 규모 및 노출도 높음
A(가격 접근성)	고가 공연에 대한 상대적 장벽 평가	평균판매단가, 회차당매출	단가가 중간 이하이면 중립,

			단가가 높고 매출이 낮으면 점수 하락
--	--	--	----------------------

표 5. USA 지표에 대한 설명

※ A 점수는 초고가 공연에만 감점 요소를 적용하며, 지나치게 낮은 가격에 대해선 별도의 보상이 주어지지 않음. 이는 단가를 무작정 낮추기보다는, 합리적인 가격대 내에서의 공연 접근성 확보를 유도하기 위한 설계임.

2.2. 복합 저변-중심 D-PI 산출 절차

a. 가중치 설정 및 전역 원저

본 지표에서는 유료 공연과 무료 공연의 구조적 차이를 반영하기 위해, 지표 산출 시 사용되는 가중치를 구분하여 적용하였다.

- 유료 공연의 경우, 관객 참여도(U), 공연 규모(S), 가격 접근성(A)에 각각 45%, 35%, 20%의 가중치를 부여하였다.
- 무료 공연은 가격 요인의 영향력이 낮다고 판단하여, 참여도(U) 60%, 규모(S) 40%로 단순화된 가중치를 적용하였다.

또한, 분석에 사용되는 수치 데이터는 극단값(Outlier)에 민감할 수 있기 때문에, 이를 보정하기 위해 전역 윈저링(Winsorization)을 적용하였다. winsor_global 함수는 각 수치형 컬럼에 대해 하위 5% 및 상위 95% 백분위수를 기준으로, 그 바깥에 위치한 극단값을 해당 경계값으로 잘라내어 반환한다. 이는 데이터의 왜곡을 줄이고, 보다 안정적인 정규화 및 백분위 계산이 가능하도록 하기 위한 전처리 과정이다.

b. 접근성 가산점 계산

접근성 점수는 공연장의 물리적 접근성과 편의성을 정량화하기 위해 설계되었다. 이를 위해 공연장 데이터에 포함된 편의시설·장애인시설·주차시설 여부 항목을 활용하였다. 각 항목은 Y/N 형식으로 제공되며, 시설이 존재하면 Y, 존재하지 않으면 N으로 표시된다. 본 프로젝트에서는 이 중 Y로 표시된 항목의 개수를 합산하여 접근성 점수로 산출하였다.

1. 접근성 점수 정규화

- 원자료의 접근성 점수(접근성_점수)는 0~11 범위에서 측정된다.
- 이를 0~1 사이로 정규화하여 기준화하였다.

2. 전역 평균 대비 보너스 산출

- 각 공연장의 점수는 전체 평균과의 차이에 따라 $\pm\beta$ 배율을 적용한다.
- 가중치의 왜곡을 막기 위해 최종 보너스 배율은 0.90~1.10 범위로 캡핑(cap) 처리하였다.

3. 최종 D-PI 반영

- 산출된 보너스 가중치는 기존의 D-PI Core 지수에 곱해져 최종 D-PI Plus로 확장된다.

이를 통해 단순히 “값이 싸거나 많이 팔린 공연”이 아니라, 더 많은 사람들에게 개방적이고 접근 가능한 공연이 정량적으로 우대되도록 설계되었다.

c. U/S/A 계산

지표 산출을 위한 핵심 구성 요소인 U(참여도), S(접점/규모), A(가격 접근성)은 모두 전역 정규화 및 백분위 기반 지표로 계산되며, 각각의 특성에 맞는 방식으로 정량화되었다.

- U (참여도)는 공연의 좌석 점유율을 기반으로 산출된다. 최종_좌석점유율 데이터를 사용하며, 극단값 보정을 위해 윈저링(winsorization, 하위 5% 및 상위 95% 클리핑)을 적용한 후, 전역 백분위(rank pct) 방식으로 정규화한다. 이를 통해 참여도 점수(U)는 0~1 구간으로 스케일링되며, 상대적인 좌석 활용도를 반영한다.
- S (접점/규모)는 공연이 관객과 접촉한 물리적 범위나 규모를 나타내는 지표로, 세 가지 요소를 결합하여 계산된다. 총 공연 회차, 판매좌석수 합계, 평균 판매좌석수 데이터를 각각 로그 정규화 및 백분위화한 후, 가중 평균(0.5 / 0.3 / 0.2)을 적용하여 하나의 지표로 통합한다. 결과적으로, 다양한 공연 활동의 규모가 정규화된 범위(0~1)로 표현된다.
- A (가격 접근성)은 평균 판매 단가를 활용하여, 공연의 경제적 접근성을 평가한다. 평균 단가가 높을수록 접근 장벽이 크다고 판단하여, 백분위화한 후 역순(1 - 백분위)으로 계산하며, 결과적으로 단가가 낮은 공연일수록 A 점수가 높게 나타난다.

이렇게 정량화된 U, S, A 지표는 이후 유/무료 여부에 따라 구분된 방식으로 결합되어 Core DPI를 산출한다. 최종적으로는 평균판매단가 또는 회차당매출이 0 이하인 경우를 무료 공연으로 간주하여, 조건문을 통해 DPI_core 값을 유료/무료에 따라 자동 선택하도록 구성하였다.

d. 지역 격차 보정

공연의 지역별 편중 현상은 문화 접근성 평가에서 중요한 고려 대상이다. 따라서 본 지표에서는 지역 간의 성과 차이를 완화하고, 지역 균형성을 고려한 보정을 수행하기 위해 DPI_plus 점수에 대해 지역 보정 로직을 적용하였다. 이 보정 과정은 유/무료 공연 세그먼트별로 독립적으로 진행되며, 각 세그먼트 내에서 보정 강도(K)와 점수 이동 허용 한도(CAP)라는 두 가지 하이퍼파라미터를 최적화하여 적용한다.

지역별 보정은 다음과 같은 수식에 기반한다:

$$\begin{aligned} \text{보정 점수} &= \text{원점수} - \Delta \\ \Delta &= \alpha \times (\text{지역 평균} - \text{전체 평균}) \\ \text{단, } \alpha &= n_{\text{region}} / (n_{\text{region}} + K), \Delta \text{는 } \pm \text{CAP 범위로 클립} \end{aligned}$$

이때 K는 수축 정도를 조절하는 파라미터로, 클수록 지역별 평균에 덜 민감하게 반응하며, CAP

은 지역 이동점수의 최대 허용치를 결정한다. 결과적으로, 지역의 표본 수가 작을수록 전체 평균에 가까워지도록 유도하며, 과도한 점수 조정을 방지한다.

평가항목	설명
η^2 (지역 효과)	ANOVA 기반 지역 간 분산 비율
RMS 편차	지역 평균과 전체 평균 간의 가중 평균 제곱근 편차
왜곡 크기 (95% 절대값)	점수 조정 크기의 95퍼센타일
Spearman 상관	보정 전후 순위 일관성

표 6. 지역 효과 보정 평가 항목

이 과정에서 지역 간 편차를 평가하는 데 사용된 핵심 지표는 ANOVA 기반 η^2 (eta-squared)와 지역 평균의 RMS 편차 두 가지이다. 이 두 지표는 각각 상대적 편향(η^2)과 절대적 편차(RMS)를 보여주기 때문에, 하나만으로는 지역 효과를 완전하게 파악하기 어렵다. 예를 들어, 점수 스케일이 조정되면 RMS는 함께 변하지만, η^2 는 스케일과 무관하게 구조적 편향의 영향을 지속적으로 측정할 수 있다. 따라서 본 보정 절차에서는 두 지표를 동시에 고려하여 보정 성능을 평가하고, 지역에 따른 왜곡을 최소화할 수 있는 최적의 파라미터(K, CAP)를 탐색하였다.

이 네 지표는 각각 다른 스케일을 갖기 때문에, 0~1 사이로 **min-max 정규화**한 후, 가중합 점수로 통합된다. 단, Spearman 상관계수가 0.90 미만일 경우에는 **추가 벌점**이 부여되어, 지나친 순위 왜곡이 발생한 보정 조합은 자동으로 페널티를 받도록 설계되어 있다. 최종적으로는 **점수가 가장 낮은 조합**(즉, 지역 효과를 가장 효과적으로 줄이고 왜곡은 가장 적은 조합)이 최적의 보정 파라미터로 선택된다.

e. 세그먼트별 최적 K/CAP 탐색 및 적용

평가 대상은 Paid(유료 공연)와 Free(무료 공연) 두 세그먼트로 나뉜다. 각 세그먼트에서 정의된 평가 그리드(K: 30~150, CAP: 2.0~6.0)를 탐색하며, 가장 낮은 평가 점수를 기록한 K/CAP 조합을 **최적 하이퍼파라미터**로 선택한다. 선택된 최적값은 이후 해당 세그먼트의 모든 공연 데이터에 적용되며, 다음 세 가지 컬럼이 새로 생성된다.

DPI_region_adj_seg: 보정된 DPI 점수

DPI_region_pr_seg: 지역 내 상대 백분위 순위

region_delta_seg: 보정으로 인해 이동된 점수 차이 ($\pm$)

지역 보정 프로세스는 지표의 객관성과 형평성을 높이기 위한 핵심 단계로, 공연의 유통 지역에 따른 점수 편향을 정량적으로 완화하며, 동시에 순위 일관성과 왜곡 최소화를 병행 고려하는 구조

로 설계되었다. 이는 단순한 지역 가중치 보정이 아닌, 통계 기반의 다목적 최적화 접근이라 할 수 있다.

<⑥ DPI를 통한 성과 분석>

복합 공연과 단일 장르 공연에 대한 DPI를 비교하고, 공연장 규모 및 장르 조합별 성과를 판정, 이에 대한 원인을 분석하고, 차후 개선 방향성에 대한 제고를 진행하였다.

1) 판정

먼저 복합 공연과 단일 공연의 평균 지표를 비교한 결과, 복합 공연이 전반적으로 우수한 성과를 보였다. 종합 지수(DPI_plus)는 복합 공연이 51.98로 비복합 공연의 45.06보다 6.92포인트 높게 나타났다. 이는 복합 공연이 저변 확대 효과에서 명확한 우위를 차지함을 보여주었다.

지표	복합 평균	비복합 평균	차이(복합-비복합)
DPI_plus	51.978990	45.057639	6.921350
U_participation	0.500714	0.500013	0.000701
S_scale	0.500714	0.500013	0.000701
A_afford	0.427556	0.390496	0.037060

표 7. 복합/비복합 DPI 및 USA 지표 점수 비교

세부 지표를 살펴보면, 참여 안정성(U_participation)과 규모 접근성(S_scale)은 두 집단 모두 0.500 수준으로 큰 차이는 없었지만, 복합 공연이 미세하게 높았다. 특히 경제적 접근성(A_afford)의 경우 복합 공연이 0.428로, 비복합 공연의 0.390보다 크게 높아 관객의 가격 부담을 완화하는 효과가 확인되었다. 이러한 결과는 복합 장르 공연이 참여 확대와 가격 친화성에서 동시에 강점을 발휘할 수 있음을 시사하였다.

단일 A/B 평균 vs 복합 A+B DPI 비교

산점도는 단일 장르 A와 B의 평균 DPI(DPI_mean_AB)와 복합 장르의 성과(DPI_plus)를 비교한 것이다. 가로축은 단일 장르 평균, 세로축은 복합 장르 DPI를 의미하며, 평균보다 높은 성과를 기록한 경우 초록색(성공), 평균 미만인 경우 빨간색(실패)으로 표시하였다.




그림 5. 단일 및 복합 장르 간 평균 DPI (유료 공연)




그림 6. 단일 및 복합 장르 간 평균 DPI (무료 공연)

유료 공연에서는 성공률이 37.7%에 그쳤으나, 성공 시 상승 폭이 컸다는 특징이 드러났다. 반대로 무료 공연은 성공률이 40.4%로 조금 더 높았으나, 성과 분포가 넓게 퍼져 있어 성과 안정성이 낮았다. 이는 유료 공연이 집중된 자원 투입을 통해 소수의 조합에서 큰 성과를 내는 반면, 무료 공연은 다양한 시도로 관객 저변을 넓히되 개별 성과는 제한적임을 보여준다.

이와 같은 결과는 복합 장르가 반드시 단일 장르 평균을 능가하는 것은 아니며, 성공과 실패가 뚜렷하게 갈리는 구조적 특징을 가지고 있음을 시사한다. 이러한 현상을 보다 명확히 확인하기 위해, 아래에서는 단일 장르와 복합 장르의 DPI를 직접 막대 그래프로 비교하여 각 사례의 구체적인 양상을 검토하였다.

단일 및 복합 장르 DPI지수 비교




그림 7. 단일 및 복합 장르 DPI 지수 비교(유료, 무료, 샘플 20개 기준)

막대 그래프는 단일 장르 A, B와 복합 장르 A+B의 DPI를 나란히 비교한 결과이다. 여러 조합에서 복합 장르가 단일 평균을 능가했지만, 일부 조합은 오히려 단일 장르보다 낮은 성과를 보였다. 예를 들어, 대중무용+연극은 복합 장르가 단일 평균을 초과했지만, 대중음악+무용은 오히려 단일 평균보다 성과가 떨어졌다.

전체적으로 복합 장르가 단일 평균보다 우위에 있었던 비율은 약 38~40% 수준이었다. 이는 복합 장르 결합이 일정 비율에서는 뚜렷한 성과 향상을 만들어내지만, 절반 이상에서는 효과가 제한적이었음을 보여준다.

결과는 복합 장르 공연이 단순 결합만으로 성과를 보장하지 않는다는 점을 분명히 한다. 즉, 복합 공연은 특정 조건(장르 공합, 공연 규모, 자원 투입)에 따라서는 단일 평균을 뛰어넘지만, 반대의 경우 평균에도 못 미치는 실패를 기록한다. 따라서 복합 장르는 “고위험·고성과(high risk-high return)” 구조를 가지며, 기획 단계에서 세밀한 조합 전략이 요구된다.

성공 실패 DPI분포

박스플롯은 성공과 실패 그룹 간 DPI 분포 차이를 보여준다. 유료 공연에서는 성공 그룹의 중앙값이 55~60, 실패 그룹은 35~40 수준으로 명확히 분리되었다. 무료 공연에서도 동일한 경향이 나타났다으며, 성공 그룹은 중앙값이 55~60, 실패 그룹은 30대에 불과하였다.




그림 8. 복합 장르 성공 실패 여부 DPI boxplot (유료, 무료)

통계적으로도 이 차이는 유의미하였다(t-test, $p < 0.01$). 즉, 복합 장르 공연이 성공할 경우 확연히 높은 DPI를 기록하지만, 실패할 경우 단일 평균에도 미치지 못하는 양극화 현상이 발생한다는 점이 확인되었다. 이러한 현상이 장르별로 어떻게 달라지는지는 아래의 히트맵 분석을 통해 보다 구체적으로 드러난다.

통계 검증: 평균 차이 검정(Welch t-test)

박스플롯으로 확인한 성공·실패 집단 간 DPI 분포 차이가 **우연에 의한 것인지를** 검증하기 위해, 표본의 분산이 다를 수 있음을 고려해 Welch t-test(양측, $\text{equal_var}=\text{False}$)를 적용하였다. 비교 단위는 **복합 조합 내 ‘성공($A+B \geq \text{mean}(A,B)$)’ vs ‘실패(미만)’** 두 집단이고, 종속변수는 **DPI_plus**이다.

지표	복합 평균 (n=477)	비복합 평균 (n=35,980)	t	p
DPI_plus	40.6553	44.6132	-5.0266	7.00e-07
U_participation	0.4848	0.5042	-1.4871	0.1376
S_scale	0.4813	0.5133	-3.9722	8.18e-05
A_afford	0.3376	0.4549	-12.9580	2.63e-33

표 8. 유료 공연에 대한 t-test

지표	복합 평균 (n=228)	비복합 평균 (n=4,091; A는 n=3,562)	t	p
DPI_plus	51.3927	41.3985	6.5424	3.41e-10
U_participation	0.5340	0.4633	3.4925	5.65e-04
S_scale	0.5413	0.3994	12.0475	1.45e-26
A_afford	0.8376	0.9549	-1.54e16	≈ 0

표 9. 무료 공연에 대한 t-test

성공 실패 상위조합




그림 9. 성공 및 실패 상위 조합의 DPI 바 차트 (유료, 무료)

바 차트는 성공 및 실패 상위 조합을 구체적으로 제시한다. 유료 공연에서는 무용+뮤지컬, 대중 무용+한국음악이 높은 성과를 기록했으며, 대중음악+무용, 대중무용+뮤지컬은 실패 조합이었다. 무료 공연에서도 유사한 경향이 나타나, 무용과 연극 계열 조합은 상대적으로 성공적이었지만, 대중음악 계열은 실패 가능성이 높았다.

수치적으로 성공 조합의 DPI는 평균 65 이상이었고, 실패 조합은 30대 후반 이하에 머물렀다. 이는 장르 궁합이 곧 성과를 좌우한다는 점을 실증적으로 보여준다.

성공 실패 비율

복합 장르 공연의 성과는 유료와 무료 공연에서 차이를 보였다. 분석 결과, 유료 공연의 복합 장르 성공률은 37.7%, 무료 공연의 성공률은 40.4%로 나타났다. 단순히 성공률만 놓고 보면 무료 공연이 소폭 높았지만, 실제 성과의 맥락을 해석하면 양자의 차이는 본질적으로 자원 배분 구조에 기인하였다.



그림 10. DPI에 따른 성공 실패 비율 (유료, 무료)

- **유료 공연**은 티켓 판매를 통해 직접적인 수익 창출을 목표로 하기 때문에, 공연의 기획·연출·홍보 단계에서 더 많은 자원이 투입된다. 이 과정에서 장르 융합의 효과가 보다 정교하게 구현될 수 있었고, 따라서 유료 공연은 **소수의 성공 조합이 큰 성과를 기록하는 경향**을 보였다. 즉, 성과 분포가 양극화되어, 성공한 공연은 매우 높은 DPI를 기록한 반면, 실패한 공연은 평균보다 크게 뒤처졌다.
- **무료 공연**은 접근성 제고를 목표로 하여 더 다양한 시도와 장르 융합이 이루어졌으나, 상대적으로 자원 투입이 제한적이었다. 이로 인해 복합 효과가 충분히 발휘되지 못하는 경우가 많았다. 그럼에도 무료 공연은 관객 저변 확대 차원에서 의미가 있었으며, 다양한 장르 실험이 관객 참여 안정성을 높이는 데 기여하였다. 다만 전체적으로는 **성과의 질적 수준이 유료 공연에 비해 고르게 낮았다**.

결론적으로, 유료 공연은 집중된 자원 투입 → 성과 극대화 가능, 무료 공연은 다양한 실험과 접근성 확보 → 평균적 확산 효과라는 차별성을 보였다.

<판정에서 원인으로: 실패 표본을 별도 분리한 이유>

앞선 판정 파트에서 우리는 Mean 기준($A+B \geq \text{mean}(A,B)$)으로 복합의 성공/실패를 구분했고, 성공률이 유료 37.7% / 무료 40.4%, 실패 그룹의 DPI 중앙값이 30대 중후반, 성공 그룹은 55~60 수준으로 유의미한 격차(t-test, $p < 0.01$)가 있음을 확인했다. 이 결과는 “복합은 고위험-고성과 구조”라는 사실을 보여주지만, 왜 실패했는지(병목이 무엇인지)는 설명하지 못한다. 따라서 본 절에서는 실패 표본만 따로 모아 U/S/A의 분포와 상관 구조를 들여다봐 개선 레버를 식별한다.

분포 진단: 박스플롯 및 히스토그램




그림 11. 유료 및 무료 공연 중 실패한 사례의 U/S/A 분포

먼저 분포 진단 결과, 유료 실패 표본의 핵심 병목은 참여율(U)로 확인되었다. 평균이 0.28, 범위가 0.07~0.46이며 분포의 좌측 꼬리가 두텁게 나타난다. 스케일(S)은 평균 0.45, 범위 0.20~0.66으로 중간 수준에 모여 있어 단독 병목으로 보기 어렵고, 가격접근성(A)은 평균 0.45, 범위 0.18~0.67로 분산은 존재하지만 U에 비해 영향의 중심은 약하다. 무료 실패 표본은 성격이 다르다. U 평균이 0.31로 유료보다 높지만 분산이 더 크고, S 평균은 0.48(범위 0.19~0.72)로 대형 스케일에서도 실패가 확인된다. A는 약 0.386으로 상수처럼 움직여 분별력이 없다. 이 결과는 "유료는 U 병목, 무료는 U와 S의 조합 실패"라는 요약으로 정리된다.

실패 공연 - U/S/A 지표 Boxplot (유료 vs 무료)




그림 12. 유료 및 무료 공연 중 실패한 사례의 U/S/A Boxplot

집단 간 분포의 차이는 박스플롯으로 확인하면 명확해진다. 유료 실패 표본의 U 중앙값과 사분위 범위가 무료보다 낮고 좁게 형성되어 있어 구조적 저참여가 특징이며, 무료 실패 표본의 S는 중앙값과 분산이 모두 더 커 공간·회차 배치 등 스케일 의사결정의 실패 가능성이 높다. A는 무료에서 거의 고정값으로 관찰되어 개선 여지가 제한적이다.




그림 13 유료 및 무료 공연 중 실패한 사례의 U/S/A 상관관계

상관 구조는 pairplot에서 확인했다. 유료 실패 표본에서는 U와 S가 약한 양의 상관을 보이며, U가 상승할 때 공간 활용도 또한 동반 개선되는 경향이 나타난다. 반면 무료 실패 표본에서는 A가 상수에 가까워 실질적인 변화 측이 U-S 2변수로 수렴한다.

요약하자면, 유료 실패의 본질은 참여율 저하이며 S/A는 보조적 변수이고, 무료 실패는 U와 S의 조합 의사결정이 핵심이다.

<원인에서 개선으로: 회귀 모델을 통한 예측>

실패 표본(복합 A+B의 DPI가 성공선 $\tau = \text{mean}(A, B)$ 미만인 조합)을 대상으로, 각 표본의 현재 지표 $x=(U, S, A)$ 에서 최소한 어느 정도의 개선 $\Delta=(\Delta U, \Delta S, \Delta A)$ 를 가하면 예측 DPI가 성공선을 넘는지를 계산했다.

랜덤포레스트(Random Forest, RF) 회귀를 예측 엔진으로 선택한 근거는 다음과 같다.

1. 데이터 특성상 입력(U, S, A)은 0-1 경계 제약을 가진 연속형이며, 장르·규모·유형에 따른 이질성과 비선형 상호작용이 존재한다. RF는 트리 양상불 특성상, 스케일링 없이도 비선형·교호효과를 포착하고 이상치·이분산에 강해, 소수 피쳐(3개)라도 복잡한 결정경계를 안정적으로 학습한다.
2. 무료 데이터처럼 A가 거의 상수에 가까운 경우 선형회귀는 계수 추정이 불안정해지거나 다중공선성의 영향을 크게 받는데, RF는 분할기반이라 이런 편향에 덜 민감하다.
3. 해석 가능성이 충분하다. 전역적으로 특성 중요도(퍼뮤테이션/기본 중요도)로 "어떤 레버가 DPI를 주도하는가"를 정량화하고, 국소적으로는 부분의존(또는 ICE) 곡선으로 "U를 얼마 올리면 기대 DPI가 어떻게 변하는가"를 시각화할 수 있어 처방 해석이 쉽다.

대안 모델로는 XGBoost/LightGBM, 선형/릿지 등이 있으나, 각각 하이퍼파라미터 민감도가 커 재현성과 설명 가능성이 떨어지고, 비선형·포화구간을 설명하지 못하여 부합하지 않는다. RF는 이들 대비 성능·강건성·설명력·운영 복잡도 간 균형점에 위치한다.

랜덤포레스트 회귀의 설명력은 유료 $R^2=0.918$ (MSE=18.8), 무료 $R^2=0.884$ (MSE=19.9)로 **비선형·상호작용을 포함한 예측에 충분한 수준**을 확보했다. 피쳐 중요도는 유료·무료 모두 **U_participation(고객 참여율/안정성)**이 압도적 1순위였고, S_scale은 보조적, A_afford는 유료에서만 미미한 영향이 있었으며 무료에서는 사실상 영향이 없었다. 이는 앞선 실패 진단에서 관찰한 "유료=U 병목, 무료=U+S 조합 병목, 무료의 A는 상수"라는 분포·상관 구조와 일치한다.




그림 14. 무료 및 유료 공연의 U/S/A Feature Importances

이 중요도 결과를 전제로 '실패 표본의 성공선 돌파(=A/B 평균) 최소 개선 처방'을 탐색한 결과, 유료는 실패 표본의 80.0%가 최소 개선만으로 전환되었고, 평균 개선량은 $\Delta U = +0.105$, $\Delta S = +0.054$, $\Delta A = +0.040$ 이었다. 유料的 평균 초기 격차(gap_before)는 7.71, 개선 후 평균 마진(margin_after)은 +0.27로, 대부분의 표본이 소폭이라도 성공선을 상회하도록 만드는 처방이 가능함을 의미한다. 즉 유료에서는 U를 약 +0.10 수준으로 끌어올리는 것이 가장 비용 대비 효과적이며, 필요 시 S/A를 소량 보강하는 전략이 합리적이다.




그림 15. 유료 공연의 U/S/A 최소 개선 평균

반면 무료는 전환 성공 비율이 63.2%로 유료보다 낮고, 평균 개선량은 $\Delta U = +0.121$, $\Delta S = +0.075$ ($\Delta A = 0$)로 유료보다 더 큰 개선 폭이 요구되었다. 평균 초기 격차는 12.14로 유료보다 크고, 개선 후 평균 마진은 -1.46으로 나타나 평균적으로는 아직 성공선에 다소 못 미침을 시사한다. 이는 무료 표본 중 상당수가 U와 S를 동시에 의미 있게 끌어올려야만 성공선에 도달한다는 뜻이며, A가 사실상 상수이기 때문에 가격 레버로 전환시키기 어려운 구조를 반영한다. 즉 무료에서는 참여 설계(U)와 스케일·회차·좌석 운용(S)의 동시 최적화가 필수다.




그림 16. 무료 공연의 U/S/A 최소 개선 평균

요약하면, 유료=U 단일 레버 중심의 저비용 처방으로 대다수 전환 가능, 무료=U+S 복합 레버를 동시에 작동해야 유의한 전환 확보라는 전략적 차이를 제시한다. 이 결과는 앞선 판정·원인 단계와 정합적이다. 유료의 U 지배력은 피처 중요도와 가벼운 ΔS/ΔA 보조 처방으로도 평균 양(+)의 margin_after를 확보하는 데 유리하며, 무료는 A의 비작동(상수)로 인해 홍보·참여 설계(U)와 공간·회차 배치(S)의 실질 개선 없이는 성공선 도달이 어렵다.

마무리하면, RF 예측 모델을 통해 실패 표본에 대해 성공선(=단일 평균) 돌파를 위한 최소 개선량(ΔU/ΔS/ΔA)을 표본 단위로 산출하였다 분석 결과는 일관되게 U(참여율/안정성)가 1순위 레버임을 확인했고, 유료는 ΔU≈+0.10에 소폭의 ΔS·ΔA 보강으로 80% 전환, 무료는 ΔU≈+0.12와 ΔS≈+0.08의 동시 개선이 필요(전환 63%)**하다는 정량 기준선을 제시했다. 이는 “유료=저비용·고효율(참여 캠페인 중심) / 무료=구조개선형(참여 설계+스케일 운용 동시 개선)”이라는 차별화된 실행 원칙으로 바로 번역된다.

정책·실무 관점에서 모델은

- (1) 조합별 성공 가능성 사전 평정
- (2) 예산 대비 효과(ΔDPI/비용) 최대화 순위
- (3) 최소 개선량을 목표치로 한 KPI 설계

위 3가지를 지원한다.

결론적으로, “왜 실패했는가”를 진단(U/S/A 병목) → “어떻게 뒤집을 것인가”를 처방(최소 ΔU/ΔS/ΔA)**까지 한 번에 연결하는 실행형 도구로 검증되었다. 이후 단계로 운영 파일럿에서 (a) 전환율 향상, (b) 예측오차(RMSE), (c) 단위예산당 ΔDPI를 KPI로 모니터링하며, KOPIS 지표 파이프라인과 연동해 상시 업데이트·재학습 체계를 갖추면, 복합 전략의 저변 확대 효과를 지표와 모델로 지속적으로 증명할 수 있다.

3) 활용 가능성 및 방향

본 프로젝트의 결과물은 기획·편성 단계의 의사결정, 정책·평가 체계 수립, 그리고 플랫폼·서비스화까지 세 가지 층위에서 즉시 활용될 수 있다.

1. 성공선(Mean)을 명시한 객관적 판정을 제시한다
2. 실패 사례에 대한 원인을 U/S/A(이용·사회적 확산·접근성) 지표로 세분화하여 분석한다.
3. 각 사례별 최소 개선량($\Delta U/\Delta S/\Delta A$)을 함께 처방한다

이를 통해 과거 경험적·주관적 판단 중심으로 이뤄지던 공연 및 문화 기획 의사결정을 정량적·데이터 기반 의사결정으로 전환할 수 있는 기반이 마련된다.

<KOPIS의 적용 방향>

우선 KOPIS 데이터와의 통합 활용을 상정할 수 있다. 이를 위해 표준 분류와 정규화 체계를 고도화하여 장르명을 정제하고, 동의어 사전 및 조합키를 활용해 데이터 비교의 일관성을 높인다. 또한 공연장의 규모를 좌석수를 기준으로 구간화하여 메타데이터로 상시 저장함으로써, 동일한 조건에서의 성과 비교가 가능하도록 한다.

이와 함께 KOPIS 내부에서 공연 단위의 U/S/A/DPI_plus 지표를 일·주·월 단위로 정기 산출하고, 이를 API 형태로 외부 기관이나 지자체, 민간 기획사에도 개방하는 방안이 제안된다. 사용자는 장르, 공연 유형, 규모, 예상 U/S/A 값을 입력하면, API는 예상 DPI와 성공선 돌파 여부, 최소 개선량, 그리고 대안 조합을 산출한다. 이러한 기능은 기획 초기 단계에서 사전 리스크를 줄이고, 비용 대비 효과적인 전략 선택을 가능하게 한다.

더 나아가 대시보드 및 시뮬레이터를 SaaS 형태로 구축해, 사용자가 지역·규모·예산 시나리오를 입력하면 $\Delta U/\Delta S/\Delta A$ 조합 탐색과 편성 후보군 랭킹 제공이 가능해진다. 이는 실패 사례를 별도로 분석하여 현재의 성과 격차와 개선 가능성을 시뮬레이션하는 등, 기획 의사결정의 실질적인 지원 도구로 작동할 수 있다.

<정책 및 현장 적용>

정책 차원에서는 보조금이나 기금 심의 과정에서 예상 DPI와 저변 확대 효과를 기반으로 사전 평가를 실시할 수 있다. 성과 평가에서는 예측치와 실제 결과 간 오차(RMSE)를 근거로 모델을 반복 학습하고, 지역이나 계층에 따른 편향 여부를 공정성 메트릭으로 점검함으로써, 투명하고 재현 가능한 평가 체계 확립이 가능해진다. 현장 실무에서는 기획자가 장르, 유형, 규모, 예상 지표만 입력하면 DPI와 성공 가능성을 즉각적으로 확인할 수 있고, 무작위적 조합 시도를 줄이는 대신 ROI가 높은 조합에 자원을 집중할 수 있다.

또한 가격, 프로모션, 공간 정책 설계에서는 공연이 유료인지 무료인지에 따라 개선 레버의 우선 순위가 달라진다. 유료 공연은 참여 촉진 → 가격 장벽 완화 → 공간 접근성 개선 순으로 조정하는 것이 효과적이고, 무료 공연은 U와 S 지표 동시 개선이 핵심 전략이 된다. 아울러 실패 상수 조합을 사전에 차단하는 히트맵 분석을 통해 디스시너지를 예방하고, 무료·소규모 시사회에서 시작해 유료·대규모 본 공연으로 전환하는 단계적 전략을 체계화할 수 있다.

<사업화 및 확장 가능성>

사업화 측면에서는 먼저 지자체, 공공기관, 대형 기획사를 대상으로 한 구독형(B2G/B2B) 분석·추천·시뮬레이션 플랫폼을 제안할 수 있다. 동시에 관객 세그먼트별 번들링·패스 추천을 제공하는 B2C 서비스로도 확장하여 관객의 이용(U)과 지불여력(A) 지표를 직접 개선할 수 있다. 아울러 신규 페스티벌이나 복합 프로젝트를 대상으로 데이터 컨설팅과 수요예측 패키지를 제공하는 서비스 모델도 가능하다.

4) 기대효과

<정량적 성과와 운영 효율>

본 체계가 현장과 정책 플랫폼에 적용될 경우, 정량적 성과와 운영 효율이 동시에 개선될 것으로 예상된다. 현재 복합 공연의 성공률이 약 40% 수준임을 고려할 때, 본 프로젝트에서 제시한 방식으로 상위 20개 실패 조합에 대해 U와 A, 혹은 U와 S를 일정 수준 개선했을 경우, 예측된 DPI가 성공선을 초과하는 비율이 유의하게 증가하는 것으로 확인되었다. 이는 단위 금액당 Δ DPI를 KPI로 설정하고, 프로모션·가격 정책간 비용-효과 곡선을 비교함으로써 예산 활용의 효율성을 극대화할 수 있음을 의미한다.

<사업적 효과>

사업적 효과 역시 뚜렷하다. 편성 성공률이 올라감에 따라 흥행 확률이 상승하고, 예측 기반의 동적 가격·번들링이 매출과 점유율을 동시에 개선할 수 있다. 또한 실패 조합을 사전에 차단함으로써 손실 리스크를 줄이고 기회비용 절감 효과를 가져온다.

<정책적 가치>

정책적 측면에서는 '감'에 의존하지 않고, 지표와 모델 기반으로 복합 전략을 설계할 수 있어 정책 신뢰도를 높일 수 있다. 이는 소·중규모 지역 공연의 성공 경로를 구체적으로 제시하고, 지역 문화 균형 발전에도 기여할 수 있다. 더 나아가 KOPIS의 표준 지표와 API 연동을 통해 분석 결과가 투명하고 재현 가능하게 공유됨으로써 제도적 활용성이 제고된다.

<문화 및 관객 경험 개선>

문화적 가치와 관객 경험도 발전할 수 있다. 새로운 장르 조합의 가능성을 데이터로 검증하고, 실패 상수 조합을 연출·구성 단계에서 재설계함으로써 창의성을 확장할 수 있다. 또한 가격과 참여 레버를 체계적으로 설계하여 신규 관객의 유입을 촉진하고, 관람 체류 시간을 늘려 공연 생태계 전반의 활력을 높일 수 있다.

<실행 로드맵>

마지막으로 실행 로드맵은 운영 파일럿(8주)을 통해 2개 기관과 2개 지역에서 대시보드와 시뮬레이터를 시범 적용해, 성공선 돌파 비율, 예측 오차(RMSE), 단위 예산당 Δ DPI를 성과 지표로 확인하는 것으로 시작한다. 이후 KOPIS 연동, 지표 고도화, 시계열 분석과 가격 탄력성 모델링을 추가해, 동적 가격과 교차 할인 효과를 정교하게 반영한다. 동시에 고가 장르로의 편중이나 지역·계층

편향을 점검하는 공정성 메트릭을 도입하여 윤리적이고 균형적인 발전 방향을 보장한다.

• 기타

이정희. (2019). 공연분야 공공 문화예술기관 성과평가지표의 상대적 중요도 분석: AHP 분석기법을 중심으로. *문화정책논총*, 33(1), 155–184. <https://doi.org/10.16937/jcp.2019.33.1.155> jcp.kcti.re.kr

DBpia. (n.d.). *공연분야 공공 문화예술기관 성과평가지표의 상대적 중요도 분석: AHP 분석기법을 중심으로*[색인 페이지]. 2025-09-14 접속.
<https://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE08771749> DBpia

National Theater of Korea. (2014). *국립극장 연보: Annual Report 2014*(PDF). 2025-09-14 접속.
https://www.ntok.go.kr/Down/Board/201810/2014_ntok_yearbook.pdf ntok.go.kr

영등포문화재단. (2025, 5월). *영등포문화재단 2024 연차보고서*[아카이브 페이지]. 2025-09-14 접속.
<https://www.ydpcf.or.kr/archive/view.do?pid=2166> ydpcf.or.kr

The Broadway League. (n.d.). *Statistics – Broadway in NYC*[Season statistics page]. Retrieved 2025-09-14, from <https://www.broadwayleague.com/research/statistics-broadway-nyc>
broadwayleague.com

The Broadway League. (n.d.). *Grosses – Broadway in NYC*[Weekly grosses/attendance portal]. Retrieved 2025-09-14, from <https://www.broadwayleague.com/research/grosses-broadway-nyc>
broadwayleague.com

The Broadway League. (2024). *Broadway's 2023–2024 end-of-season statistics reveal 12.3 million attendances and grosses of \$1.54 billion*[Press release]. Retrieved 2025-09-14, from <https://www.broadwayleague.com/press/press-releases/broadways-2023-2024-end-of-season-statistics-reveal-123-million-attendances-and-grosses-of-154-billion> broadwayleague.com

Society of London Theatre, & UK Theatre. (2025, May 22). *The state of British theatre in 2025: Growth, risk and the urgent need for public investment*(PDF). 2025-09-14 접속.
<https://uktheatre.org/wp-content/uploads/sites/2/2025/05/SOLTUKT-State-Of-British-Theatre.pdf>
[UK Theatre](http://UKTheatre)

BJ. (n.d.). *Interpreting Key Indicators in the Performing Arts*[PDF, 제공 자료; 인용 pp. 2, 24–25, 33]. (온라인 공개 URL 미제공—제공 파일 기준 참고)

※ 결과보고서 작성 시 유의사항

- 분량은 30페이지 이내로 작성(도표, 이미지, 그래프 등 포함한 분량)
- 하단에 제시한 목차 외 추가 내용이 있을 경우 별도 타이틀을 기재하여 작성
- 발표용 PPT 자료(30페이지 이내)는 위 결과보고서와는 별개로 제출